




Inteligencia Artificial y Aprendizaje Automático

Sesión 2: Aprendizaje clásico y
profundo

Presentan:

Dr. Ulises Olivares Pinto

Fernando Ramírez González



HPC
DATA LAB

Contenido

Proceso de ciencia de Datos

- Limpieza y preparación de datos*
- Análisis exploratorio*
- División de datos

Aprendizaje Clásico

- Regresiones

Aprendizaje profundo

- Definiciones
- Perceptrón
- Funciones de activación
- Perceptrón multicapa
- Propagación
- Entrenamiento

THE DATA SCIENCE PROCESS



Data Engineers

Data Analysts

Machine Learning Engineers

Data Scientists

Data Analytics Process




Data Design,
Experiments,
formulating
Business

Data Analytics, Telling
Stories


Machine Learning
Algorithms

A.I.


División de datos




¿Cómo dividir mis datos?



Supervised Learning




División e Iteraciones




Algoritmos de aprendizaje clásico


Linear Regression




Logistic Regression



Decision Trees




Random Forest




K-Nearest Neighbor




Support Vector Machine



K-Means Clustering





Naïve Bayes



Regresiones


El ejemplo más simple de una regresión es una **línea recta**, a través de la cual se pueden aproximar **n puntos**: $\{(x_1, y_1), (x_2, y_2), \dots (x_n, y_n)\}$.




$$y = mx + b$$

Ecuación de la recta

m = pendiente, b = intercepto



Regresión lineal – Introducción – Criterios de ajuste



- **(a)** Minimizar la suma de los residuos

$$\sum_{i=1}^n e_i = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)$$

- **(b)** Minimizar la suma de los valores absolutos de los residuos

$$\sum_{i=1}^n |e_i| = \sum_{i=1}^n |y_i - a_0 - a_1 x_i|$$

- **(c)** Minimizar el error al máximo para cada punto individual.

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_{i,\text{measured}} - y_{i,\text{model}})^2 = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2$$


Regresión lineal por mínimos cuadrados

Para determinar los valores de a_0 y a_1 se utilizan las siguiente formulas:

$$a_1 = \frac{n\sum x_i y_i - \sum x_i \sum y_i}{n\sum x_i^2 - (\sum x_i)^2}$$

$$a_0 = \bar{y} - a_1 \bar{x}$$

Donde $\bar{x}$ or $\bar{y}$ las medias de x y y respectivamente.



Regresión lineal por mínimos cuadrados

Ejemplo:

Obtener una regresión lineal utilizando los valores de x y y de la siguiente tabla. Se deberá graficar en python.


x_i	y_i	$(y_i - \bar{y})$	$(y_i - a_0 - a_1x_i)^2$
1	0.5	8.5765	0.1687
2	2.5	0.8622	0.5625
3	2.0	2.0408	0.3473
4	4.0	0.3265	0.3265
5	3.5	0.0051	0.5896
6	6.0	6.6122	0.7972
7	5.5	4.2908	0.1993
Σ	24.0	22.7143	2.9911

La función resultante es:

$$y = 0.07142857 + 0.8392857x$$

$$a_1 = \frac{n\sum x_i y_i - \sum x_i \sum y_i}{n\sum x_i^2 - (\sum x_i)^2}$$

$$a_0 = \bar{y} - a_1 \bar{x}$$



Regresión lineal


Métricas de evaluación

Coeficiente de determinación R^2

Mide la proporción de la varianza explicada por el modelo.

Valores cercanos a 1 indican buen ajuste.

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$




Regresión lineal

Métricas de evaluación

Error cuadrático medio

- Promedio del cuadrado de los errores.
- Penaliza más los errores grandes

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$





Ejemplos y ejercicios