



Inteligencia Artificial y Aprendizaje Automático

Sesión 7: Sesión práctica

Orange Data Mining

Presenta:

Dr. Ulises Olivares Pinto




THINK **BIG** SPACE



HPC
DATA LAB

Objetivo de la sesión

Construir un experimento completo de aprendizaje automático sin programar, pero conservando el razonamiento de ciencia de datos.




- | | |
|----|---|
| 1. | Introducción y demostración rápida |
| 2. | Exploración visual y lectura de datos |
| 3. | Clasificación: varios modelos, una misma pregunta |
| 4. | Evaluación, matriz de confusión y errores |
| 5. | Reto integrador y cierre |

¿Qué es Orange Data Mining?

Orange traduce el pipeline de ciencia de datos a un espacio visual:


- Cada bloque es un widget.
- Las conexiones mueven datos y resultados.
- Permite comparar hipótesis rápidamente.




Idea clave: primero se formula la pregunta, después se construye el flujo.

Instalación de Orange Data Mining

<https://orangedatamining.com/download/>



La interfaz: canvas, widgets y conexiones



Antes de iniciar: preparación mínima

Para evitar perder tiempo de taller, cada participante debe llegar con:

1
Orange instalado

2
Archivos .ows
descargados

3
Carpeta datos
disponible

4
Capturas para
evidencia

Regla de trabajo

No entrenamos modelos “al azar”. Cada flujo debe responder una pregunta concreta.


Actividad 1: Análisis de datos

01_AED_visual_iris.ows + iris.csv

Pregunta guía

¿Qué variables separan mejor las especies de Iris?

1. Identificar target y variables.
2. Observar rangos y clases.
3. Describir una relación visual.
4. Registrar una limitación.



Evidencia: captura del workflow + 3 observaciones breves.

Exploración visual: del dato a la hipótesis

Antes de elegir un algoritmo, el grupo debe poder explicar qué hay en los datos.

1

Variable objetivo

¿qué queremos predecir?

2

Tipos de datos

numéricos, categóricos,
texto

3

Distribuciones

rangos, sesgos y clases
raras

4

Relaciones

separación o traslape
visual

5

Problemas

faltantes, ruido y outliers

Mini discusión: si dos clases están completamente mezcladas en las visualizaciones, ¿qué esperamos de un modelo simple?

Preparación: no todo debe entrar al modelo

Un flujo reproducible debe mostrar cómo se seleccionan columnas y cómo se tratan los datos antes de entrenar.



Select Columns: definir target, features y columnas ignoradas.

Preprocess: imputar, normalizar o codificar según el algoritmo.


Decisión crítica: documentar qué se dejó fuera y por qué.

Actividad 2: Clasificación visual

02_Clasificacion_titanic.ows + titanic_didactico.csv

Misión

Predecir supervivencia y comparar varios modelos.



Antes de ver resultados: ¿qué modelo creen que funcionará mejor y por qué?

Cuatro modelos, una misma pregunta

1

Regresión logística

Probabilidad interpretable para clasificación.

2

Árbol de decisión

Reglas tipo “si-entonces” fáciles de explicar.

3

kNN

Predice según ejemplos cercanos.

4

Random Forest

Combina muchos árboles para reducir variabilidad.

La comparación es justa solo si todos los modelos reciben los mismos datos y se evalúan con el mismo procedimiento.

Evaluación: accuracy no cuenta toda la historia

En clasificación, cada métrica responde una pregunta distinta.

Accuracy

¿cuánto acierta en total?

Precision

de los positivos predichos, ¿cuántos sí lo eran?

Recall

de los positivos reales, ¿cuántos detectó?

F1

equilibrio entre precision y recall

AUC

capacidad de separar clases a distintos umbrales

Discusión rápida: en un problema médico, ¿qué error preferimos reducir primero?

Matriz de confusión: leer los errores

El objetivo no es solo saber si el modelo acierta: necesitamos saber cómo se equivoca.

		Predicción	
		No	Sí
Real	No	VN	FP
	Sí	FN	VP

- Seleccionar errores en Confusion Matrix.
- Enviar los casos a Data Table.
- Preguntar qué tienen en común.
- Volver al flujo y ajustar con criterio.

Buen uso de Orange: convertir una métrica en una explicación revisable.

Actividad 3: evaluación de errores

03_Evaluacion_breast_cancer.ows + breast_cancer.csv

Objetivo

Comparar modelos considerando impacto del error.

- ¿Qué significa un falso negativo?
- ¿Qué métrica deberíamos priorizar?
- ¿Qué casos fueron mal clasificados?
- ¿Cómo se explicaría el resultado a un comité no técnico?


Entregable rápido

- Modelo elegido
- Métrica justificada
- 1 caso de error
- Recomendación de mejora

Extensión opcional: agrupamiento sin etiqueta

04_Clustering_wine.ows + wine.csv

Cuando no tenemos variable objetivo, podemos explorar estructura latente.



Pregunta guía: ¿los vinos se agrupan de forma coherente aunque no usemos la clase original?

Reto integrador: construir y defender un flujo

En equipos de 2–3 personas, elegir un dataset y construir un flujo que responda una pregunta.

1 visualización
Distribución, scatter, box plot o mosaic.

1 decisión de preparación
Target, columnas ignoradas o preprocesamiento.

2 modelos comparados
O un método de clustering si no hay target.

1 conclusión
Resultado, error principal y limitación.

Producto final: captura del workflow + 3 líneas de interpretación.

Evaluación rápida de la actividad

Criterio	Qué se observa	Pts.
Workflow funcional	Widgets conectados y ejecución sin errores	30
Exploración	Visualizaciones y observaciones de datos	20
Modelado / evaluación	Comparación de modelos o interpretación de clusters	25
Interpretación	Errores, límites y utilidad práctica	20
Comunicación	Claridad de captura y conclusión	5

La rúbrica se incluye también en CSV dentro del paquete de actividades.

Archivos Orange incluidos

El paquete contiene workflows, datos y guía de uso para que la sesión sea reproducible.

01_AED_visual_iris.ows

Exploración visual con Iris

02_Clasificacion_titanic.ows

Clasificación binaria y comparación de modelos

03_Evaluacion_breast_cancer.ows

Matriz de confusión y análisis de errores

04_Clustering_wine.ows

Agrupamiento no supervisado con Wine

Cómo abrirlos: Orange → File → Open → seleccionar .ows. Si aparece un aviso de ruta, abrir el widget File y seleccionar el CSV correspondiente.

Cierre: lo importante no es el clic, sino el criterio


Tres preguntas para llevarse

1. ¿Qué quiero predecir o descubrir?
2. ¿Qué evidencias muestran mis datos?
3. ¿Dónde se equivoca mi modelo y por qué?

Orange permite ver el flujo completo: datos → análisis → modelo → evaluación → interpretación.


Capturas reales de Orange: carga y flujo de trabajo

Estas capturas permiten familiarizar al grupo con la interfaz real que utilizará durante el taller.



Widget File: selección de dataset y revisión básica de columnas.

The screenshot shows the 'File' widget interface. It includes a 'File' dropdown menu, a 'URL' field, and an 'Info' section displaying dataset statistics: 150 instances, 4 features, and 0 meta attributes. The 'Columns' section lists 5 columns: sepal length, sepal width, petal length, petal width, and iris. The 'iris' column is highlighted as a nominal target variable. A 'Report' button is visible at the bottom right.





Canvas real: workflow con File, Select Rows, Merge Data y Data Table.

The screenshot shows the Orange Canvas workflow. It includes a 'File (200)' widget connected to a 'Select Rows' widget, which is connected to a 'Merge Data' widget. The 'Merge Data' widget is connected to a 'Data Table' widget. A 'Conditions' dialog box is open, showing a condition 'type is one of'. The 'Data Table' widget displays a table with columns: type, type_img, name, images, and features. The table contains 40 rows of data, including various animal types and their corresponding image URLs.

Pregunta para el grupo: ¿qué widgets reconocen y qué creen que hace cada conexión?

Capturas reales de Orange: exploración visual y evaluación


Orange ayuda a conectar la exploración visual con la comparación de modelos.



Actividad sugerida: pedir al grupo que anticipe qué modelo elegiría antes de mostrar la métrica final.

Capturas reales de Orange: análisis de errores

La matriz de confusión vuelve visibles los aciertos y errores por clase.



Confusion Matrix: ejemplo real con clases de Iris.



Workflow real con Tree, Logistic Regression, Test & Score y Confusion Matrix.


Qué observar

- Clases con mayor confusión.
- Errores sistemáticos y no aleatorios.
- Casos para revisar en detalle.
- Decisiones de mejora del flujo.

Fuente visual: capturas oficiales de Orange Data Mining.

Clasificador de imágenes con una red neuronal

Ejemplo rápido y reproducible con Orange Image Analytics + Neural Network.



Dataset didáctico: arquitectura vs flor · 50 imágenes de entrenamiento

¿Dónde están las redes neuronales?

1. SqueezeNet preentrenada → convierte cada imagen en un vector.


2. MLP de Orange → aprende a separar las clases con esos vectores.

Importante: no entrenamos una CNN completa desde cero. Usamos una CNN como extractor de características y una MLP como clasificador.

Requisito: instalar el complemento Image Analytics desde Options → Add-ons.

Workflow en Orange: imágenes → embeddings → MLP

El flujo completo cabe en siete widgets y permite inspeccionar los errores visualmente.



Configuración sugerida
Image Embedding: SqueezeNet
MLP: 64,32 · ReLU · Adam

Evaluación
5-fold cross validation
Accuracy/CA · F1 · AUC

Análisis
Seleccionar mal clasificados
y verlos en Image Grid

Archivo: 05_Clasificador_imagenes_RN.ows

Ejercicio en clase: ¿qué arquitectura de MLP funciona mejor?

Trabajo en parejas · 20–25 min · comenzar con el workflow RETO.

1 · Completar el flujo

1. Cargar datos/imagenes_demo/
2. Usar SqueezeNet
3. Conectar Neural Network
4. Evaluar con Test & Score
5. Abrir Confusion Matrix

2 · Probar tres redes

32

64, 32

128, 64

ReLU · Adam · resultados replicables

3 · Defender una decisión


- Accuracy / CA
- F1
- N.º de errores
- Tiempo aproximado
- Ejemplos mal clasificados

Pregunta final: ¿un modelo con más neuronas necesariamente generaliza mejor?

Archivo: 05_RETO_Clasificador_imagenes_RN.ows

Extensión: predecir imágenes nuevas

Separar entrenamiento de inferencia ayuda a entender cómo se utiliza un modelo después de entrenarlo.



Limitación didáctica: las imágenes son variaciones aumentadas de dos fotografías base; el ejercicio explica el pipeline, no mide generalización real.

Archivo: 06_Prediccion_imagenes_nuevas_RN.ows • Datos: imagenes_nuevas/